

# 线性方程组

# 第三章 解线性方程组的迭代法基础—— 向量与矩阵的范数

## 3.5.1 向量的范数/\* vector norms \*/

为了研究线性方程组近似解的误差估计和迭代法的收敛性，需要对 $n$ 维向量空间 $\mathbf{R}^n$ 中的向量的“大小”给出某种度量。

衡量数的误差用到绝对值；

现代数学中常用“范数”来度量向量的“大小”。

### 3.5.1 向量的范数

#### 定义3.1 向量范数

**定义3.1** 设  $f(\mathbf{x}) = \|\mathbf{x}\|$  为定义在  $R^n$  上的实函数, 如果对任意  $\mathbf{x} \in R^n$  它满足条件:

- (1)  $\|\mathbf{x}\| \geq 0$  (  $\|\mathbf{x}\| = 0$  当且仅当  $\mathbf{x} = \mathbf{0}$  ) (正定性)
- (2)  $\|\lambda \mathbf{x}\| = |\lambda| \|\mathbf{x}\|$  (对任意常数  $\lambda \in R$  ) (齐次性)
- (3)  $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$  (对任意  $\mathbf{x} \in R^n$  ) (三角不等式)

则称  $f(\mathbf{x}) = \|\mathbf{x}\|$  为  $R^n$  上的**向量范数**

$$(4) \quad \left| \|\mathbf{x}\| - \|\mathbf{y}\| \right| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$$



## 常用向量范数:



向量的1-范数:

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$



向量的2-范数:

$$\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2}$$



向量的 $\infty$ -范数:

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$$



向量的p-范数:

$$\|x\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}$$

可以证明向量函数  $\|x\|_p$  是  $\mathbf{R}^n$  上的向量的范数（满足定义3.1），  
且前三种范数是“ $p$ ”范数的特殊情况

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2} = \left\{ \sum_{i=1}^n x_i^2 \right\}^{\frac{1}{2}}$$

$$\|x\|_1 = |x_1| + |x_2| + \cdots + |x_n| = \sum_{i=1}^n |x_i|$$


$$\|x\|_\infty = \max\{|x_1|, |x_2|, \cdots, |x_n|\}$$

$$\|\mathbf{x}\|_2 = 7.4$$

$$\|\mathbf{x}\|_1 = 12$$

$$\|\mathbf{x}\|_\infty = 5.5$$

$$\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3) = (2.0, 5.5, 4.5)$$



向量范数的几何意义

例 设  $\mathbf{x} = (-1, 2, 3)^T$  计算  $\|\mathbf{x}\|_1$ ,  $\|\mathbf{x}\|_\infty$ ,  $\|\mathbf{x}\|_2$

解

$$\|\mathbf{x}\|_1 = 1 + 2 + 3 = 6$$

$$\|\mathbf{x}\|_2 = (1^2 + 2^2 + 3^2)^{1/2} = \sqrt{14}$$

$$\|\mathbf{x}\|_\infty = \max\{1, 2, 3\} = 3$$

$$\|\mathbf{x}\|_1 = |x_1| + |x_2| + \cdots + |x_n|$$

$$\|\mathbf{x}\|_2 = (x_1^2 + x_2^2 + \cdots + x_n^2)^{1/2}$$

$$\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$$

### 定义3.2 向量收敛的定义

**定义** 向量序列  $\{\mathbf{x}^{(k)}\}$  收敛于向量  $\mathbf{x}^*$  是指对每一个  $1 \leq i \leq n$  都有  $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i^*$ 。可以理解为  $\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}^*\| \rightarrow 0$

$$\lim_{k \rightarrow \infty} \mathbf{x}_i^{(k)} = x_i^* \iff \lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}^*\| \rightarrow 0$$



### 定义3.3 矩阵范数 /\* matrix norms \*/

定义  $R^{m \times n}$  空间的矩阵范数  $\|\cdot\|$  对任意  $A, B \in R^{m \times n}$  满足:

(1)  $\|A\| \geq 0$ ;  $\|A\| = 0 \Leftrightarrow A = 0$  (正定性 /\* positive definite \*/)

(2)  $\|\alpha A\| = |\alpha| \cdot \|A\|$  对任意  $\alpha \in \mathbb{C}$  (齐次性 /\* homogeneous \*/)

(3)  $\|A + B\| \leq \|A\| + \|B\|$  (三角不等式 /\* triangle inequality \*/)

(4)\*  $\|AB\| \leq \|A\| \cdot \|B\|$  (相容 /\* consistent \*/ 当  $m = n$  时)

(5)  $\|Ax\| \leq \|A\| \cdot \|x\| \quad \|x\| \in R^n$

特别有:  $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$  (行或无穷范数)

$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$  (列或1范数)

例 设  $\mathbf{A} = \begin{bmatrix} 1 & 3 \\ -4 & 5 \end{bmatrix}$  计算  $\|\mathbf{A}\|_1$ 、 $\|\mathbf{A}\|_\infty$

解  $\|\mathbf{A}\|_1 = \max\{5, 8\} = 8$

$$\|\mathbf{A}\|_\infty = \max\{4, 9\} = 9$$

$$\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

$$\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

## 3.6 线性方程组的迭代解法

在用直接法解线性方程组时要对系数矩阵不断变换

如果方程组的阶数很高,则运算量将会很大

因此对线性方程组

$$Ax = b$$

$$\text{设 } A \in R^{n \times n}, b \in R^n, x \in R^n$$

要求找寻更经济、适用的数值解法

## 3.6 线性方程组的迭代解法

**迭代法** 是对任意给定的**初始近似解向量**，按照某种方法逐步生成**近似解序列**，使解序列的**极限**为方程组的**解**。

因此迭代法是用某种极限过程去**逐步逼近**线性方程组精确解的方法。

可以用有限步运算算出具有指定精确度的近似解。

主要方法：

1. 雅可比(Jacobi)迭代法
2. 高斯-塞德尔 (Gauss-Seidel)迭代法
3. 逐次超松弛法

例 1 设有方程组

$$\begin{cases} 10x_1 - x_2 + 2x_3 = 6 \\ -x_1 + 11x_2 - x_3 + 3x_4 = 25 \\ 2x_1 - x_2 + 10x_3 - x_4 = -11 \\ 3x_2 - x_3 + 8x_4 = 15 \end{cases}$$

或简记  $\mathbf{Ax}=\mathbf{b}$

解 精确解  $\mathbf{x}^*=(1, 2, -1, 1)^T$ 。

首先将  $\mathbf{Ax}=\mathbf{b}$  转化为等价方程组

$$\begin{cases} x_1 = \frac{1}{10}(6 + x_2 - 2x_3) \\ x_2 = \frac{1}{11}(25 + x_1 + x_3 - 3x_4) \\ x_3 = \frac{1}{10}(-11 - 2x_1 + x_2 + x_4) \\ x_4 = \frac{1}{8}(15 - 3x_2 + x_3) \end{cases}$$

或写为  $\mathbf{x}=\mathbf{Bx}+\mathbf{f}$

迭代公式：初始向量  $\mathbf{x}^{(0)} = (0, 0, 0, 0)^T$

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{10}(6 + x_2^{(k)} - 2x_3^{(k)}) \\ x_2^{(k+1)} = \frac{1}{11}(25 + x_1^{(k)} + x_3^{(k)} - 3x_4^{(k)}) \\ x_3^{(k+1)} = \frac{1}{10}(-11 - 2x_1^{(k)} + x_2^{(k)} + x_4^{(k)}) \\ x_4^{(k+1)} = \frac{1}{8}(15 - 3x_2^{(k)} + x_3^{(k)}) \end{array} \right., \quad (k = 0, 1, 2, \dots)$$

计算结果如下表：

$$\mathbf{x}^{(0)} = (0.0000, 0.0000, 0.0000, 0.0000)^T$$

$$\mathbf{x}^{(1)} = (0.6000, 2.2727, -1.1000, 1.8750)^T$$

...

$$\mathbf{x}^{(8)} = (1.0006, 1.9987, -0.9990, 0.9989)^T$$

$$\mathbf{x}^{(9)} = (0.9997, 2.0004, -1.0004, 1.0006)^T$$

$$\mathbf{x}^{(10)} = (1.0001, 1.9998, -0.9998, 0.9998)^T$$

且有误差:  $\|\mathbf{x}^* - \mathbf{x}^{(10)}\|_\infty \approx 0.0002$

从此例看出，由迭代法产生的向量序列  $\{\mathbf{x}^{(k)}\}$  逐次逼近方程组的精确解。但是，并不是对任何一个线性方程组，由迭代法产生的向量序列  $\{\mathbf{x}^{(k)}\}$  都收敛。

## 3.6.1 迭代格式的一般形式

解线性方程组的迭代法的基本思想与求非线性方程的迭代法的基本思想是类似的。

$$Ax = b$$

变形成等价的同解线性方程组

$$x = Bx + f$$

然后任取一个初始向量 $x^{(0)} \in \mathbb{R}^n$ 作为近似解，由公式

$$x^{(k+1)} = Bx^{(k)} + f \quad (k = 0, 1, 2, \dots)$$

构造向量序列 $\{x^{(k)}\}$ ，如果向量序列 $\{x^{(k)}\}$ 满足



$$\lim_{k \rightarrow \infty} x^{(k)} = x^* \quad \text{-----迭代法收敛}$$

方程组的解

否则，称此**迭代法发散**。

$$\text{迭代格式 } x^{(k+1)} = Bx^{(k)} + f \quad (k = 0, 1, 2, \dots)$$

迭代矩阵

第 $k$ 次迭代近似解

$$e^{(k)} = x^* - x^{(k)} \quad \text{-----第}k\text{次迭代误差}$$

## 用迭代法解方程组( $Ax=b$ )的关键是:

(1) 如何构造迭代格式

$$x^{(k+1)} = Bx^{(k)} + f \quad (k = 0, 1, 2, \dots)$$

**1. 雅可比(Jacobi)迭代法**

**2. 高斯-塞德尔 (Gauss-Seidel)迭代法**

**3. 逐次超松弛法**

(2) 由迭代格式产生的向量序列  $\{x^{(k)}\}$  的收敛条件是什么？

### 3.6.2 雅可比迭代法

设线性方程组  $Ax=b$  的一般形式为

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \dots\dots\dots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

雅可比 (Jacobi) 迭代法的步骤为:

(1) 设  $a_{ii} \neq 0$  ( $i=1,2,\cdots,n$ ) , 则可从上式解出  $x_i$

$$x_1 = \frac{1}{a_{11}} (b_1 - a_{12}x_2 - a_{13}x_3 - \cdots - a_{1n}x_n)$$

$$\left\{ \begin{array}{l} x_1 = \frac{1}{a_{11}}(b_1 - a_{12}x_2 - a_{13}x_3 - \cdots - a_{1n}x_n) \\ x_2 = \frac{1}{a_{22}}(b_2 - a_{21}x_1 - a_{23}x_3 - \cdots - a_{2n}x_n) \\ \dots\dots\dots \\ x_i = \frac{1}{a_{ii}}(b_i - a_{i1}x_1 - \cdots - a_{i,i-1}x_{i-1} - a_{i,i+1}x_{i+1} - \cdots - a_{in}x_n) \\ \dots\dots\dots \\ x_n = \frac{1}{a_{nn}}(b_n - a_{n1}x_1 - a_{n2}x_2 - \cdots - a_{n,n-1}x_{n-1}) \end{array} \right.$$

## (2) 写成迭代格式

$$\left\{ \begin{array}{l}
 x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)}) \\
 x_2^{(k+1)} = \frac{1}{a_{22}} (b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)}) \\
 \dots\dots\dots \\
 x_i^{(k+1)} = \frac{1}{a_{ii}} (b_i - a_{i1}x_1^{(k)} - \cdots - a_{i,i-1}x_{i-1}^{(k)} - a_{i,i+1}x_{i+1}^{(k)} - \cdots - a_{in}x_n^{(k)}) \\
 \dots\dots\dots \\
 x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)})
 \end{array} \right.$$

(3) 取定初始向量  $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_i^{(0)}, \dots, x_n^{(0)})^T$

令  $k = 0, 1, 2, \dots$

根据迭代公式 (3.23)

$$x_i^{(k+1)} = \frac{1}{a_{ii}} (-a_{i1}x_1^{(k)} - \dots - a_{i,i-1}x_{i-1}^{(k)} - a_{i,i+1}x_{i+1}^{(k)} - \dots - a_{in}x_n^{(k)} + b_i)$$
$$(i = 1, 2, \dots, n)$$

可得向量序列  $\{x^{(k)}\}$ 。

$$x^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})^T$$

类似于非线性方程的迭代法，对于事先给定的精度要求 $\varepsilon$ ，当

$$\left\| x^{(k+1)} - x^{(k)} \right\|_{\infty} < \varepsilon$$

就可以得到方程组的近似解

$$x^* \approx x^{(k+1)}$$

雅可比迭代法的矩阵形式,  $A = \tilde{L} + D + \tilde{U}$

$$\tilde{L} = \begin{bmatrix} 0 & & & & \\ a_{21} & 0 & & & \\ a_{31} & a_{32} & 0 & & \\ \vdots & \vdots & \vdots & \ddots & \\ a_{n-1,1} & a_{n-1,2} & a_{n-1,3} & \cdots & 0 \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{n,n-1} & 0 \end{bmatrix}$$

$$D = \begin{bmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & a_{33} & & \\ & & & \ddots & \\ & & & & a_{nn} \end{bmatrix}$$

$$\tilde{U} = \begin{bmatrix} 0 & a_{12} & a_{13} & \cdots & a_{1n} \\ & 0 & a_{23} & \cdots & a_{2n} \\ & & \ddots & \ddots & \vdots \\ & & & 0 & a_{n-1,n} \\ & & & & 0 \end{bmatrix}$$



则  $A = \tilde{L} + D + \tilde{U}$

线性方程组(3.18)  $Ax = b$  可表示为

$$(\tilde{L} + D + \tilde{U})x = b$$

$$\Longrightarrow Dx = b - (\tilde{L} + \tilde{U})x$$

$$\because a_{ii} \neq 0 \quad (i = 1, 2, \dots, n) \quad \therefore \det(D) \neq 0$$

$$\Longrightarrow x = D^{-1}[b - (\tilde{L} + \tilde{U})x]$$

相应的迭代格式为  $x^{(k+1)} = D^{-1}[b - (\tilde{L} + \tilde{U})x^{(k)}]$

$$x^{(k+1)} = D^{-1}[b - (\tilde{L} + \tilde{U})x^{(k)}]$$

所以Jacobi迭代格式的矩阵形式

$$x^{(k+1)} = Jx^{(k)} + f_J$$

$$J = -D^{-1}(\tilde{L} + \tilde{U})$$

-----Jacobi迭代矩阵

$$f_J = D^{-1}b$$

例. 用Jacobi迭代法求解方程组

$$\begin{cases} 20x_1 + 2x_2 + 3x_3 = 24 \\ x_1 + 8x_2 + x_3 = 12 \\ 2x_1 - 3x_2 + 15x_3 = 30 \end{cases}$$

解: 按迭代公式, 得雅可比迭代格式

$$\begin{cases} x_1^{(k+1)} = (24 - 2x_2^{(k)} - 3x_3^{(k)}) / 20 \\ x_2^{(k+1)} = (12 - x_1^{(k)} - x_3^{(k)}) / 8 \\ x_3^{(k+1)} = (30 - 2x_1^{(k)} + 3x_2^{(k)}) / 15 \end{cases}$$

取  $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, x_3^{(0)})^T = (0, 0, 0)^T$  令  $k = 0, 1, 2, \dots$

$$x^{(1)} = [1.2, 1.5, 2]^T \quad \|x^{(1)} - x^{(0)}\|_{\infty} = 2$$

$$x^{(2)} = [0.75, 1.1, 2.14]^T \quad \|x^{(2)} - x^{(1)}\|_{\infty} = 0.45$$

$$x^{(3)} = [0.769, 1.138, 2.12]^T$$

$$x^{(4)} = [0.768125, 1.138875, 2.125216667]^T$$

$$x^{(5)} = [0.76733, 1.13832292, 2.12535833]^T$$

.....

$$\begin{aligned} x^{(12)} &= [0.767353807, 1.138409760, 2.125368111]^T \\ &= x^{(13)} \end{aligned}$$

在计算机上，使用Jacobi迭代法求解方程组时，  
可用 $x$ ,  $y$ 分别表示 $x^{(k)}$ 和 $x^{(k+1)}$

当  $\max_i |x_i^{(k)} - x_i^{(k+1)}| < \varepsilon$  时，停止迭代，

## 计算步骤

(1) 对  $i=1\sim n$  令  $x_i \leftarrow 0$

(2)  $D \leftarrow 0$

(3) 对  $i=1\sim n$  做

$$\left\{ \begin{array}{l} \text{令 } y_i = b_i \\ \text{对 } j=1\sim n \text{ 但 } j \neq i \text{ 令 } y_i \leftarrow y_i - a_{ij}x_j \\ \text{令 } y_i \leftarrow y_i / a_{ii} \\ \text{若 } |x_i - y_i| > D \text{ 则令 } D \leftarrow |x_i - y_i| \end{array} \right.$$

(4) 对  $i=1\sim n$  令  $x_i \leftarrow y_i$

(5) 对  $D \geq \varepsilon$  则转到(2)

(6) 输出  $x_i$  ( $i=1\sim n$ ) 并停止计算

# 高斯-赛德尔迭代法

## 分析Jacobi迭代法的迭代过程

$$\begin{aligned}x_1^{(k+1)} &= (-a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)} + b_1) / a_{11} \\x_2^{(k+1)} &= (-a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)} + b_2) / a_{22} \\&\dots\dots\dots\end{aligned}$$

$$x_i^{(k+1)} = (-a_{i1}x_1^{(k)} - \cdots - a_{i,i-1}x_{i-1}^{(k)} - a_{i,i+1}x_{i+1}^{(k)} - \cdots - a_{in}x_n^{(k)} + b_i) / a_{ii}$$

发现在 $x_i^{(k+1)}$ 之前,  $x_1^{(k+1)}, x_2^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ 已经求出

但当求 $x_i^{(k+1)}$ 时, 仍用 $x_1^{(k)}, x_2^{(k)}, \dots, x_{i-1}^{(k)}$ 进行迭代

在算 $x^{(k+2)}$ 时才用 $x^{(k+1)}$ 代换 $x^{(k)}$ 。雅可比迭代又称同时代换法或整体代换法或简单迭代法。

能否求 $x_i^{(k+1)}$ 时, 利用 $x_1^{(k+1)}, x_2^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ 进行迭代呢?


# 高斯-赛德尔(Gauss-Seidel)迭代法或称逐个代换法

迭代公式

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (-a_{21}\mathbf{x}_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)} + b_2) \\ \qquad \qquad \qquad \cdots \cdots \cdots \\ x_i^{(k+1)} = \frac{1}{a_{ii}} (b_i - a_{i1}\mathbf{x}_1^{(k+1)} - \cdots - a_{i,i-1}\mathbf{x}_{i-1}^{(k+1)} - a_{i,i+1}x_{i+1}^{(k)} - \cdots - a_{in}x_n^{(k)}) \\ \qquad \qquad \qquad \cdots \cdots \cdots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}\mathbf{x}_1^{(k+1)} - a_{n2}\mathbf{x}_2^{(k+1)} - \cdots - a_{n,n-1}\mathbf{x}_{n-1}^{(k+1)}) \end{array} \right.$$



## 高斯-赛德尔(Gauss-Seidel)迭代法的矩阵形式

$$x^{(k+1)} = D^{-1} (b - \tilde{L}x^{(k+1)} - \tilde{U}x^{(k)})$$


$$\Rightarrow x^{(k+1)} = (D + \tilde{L})^{-1} (b - \tilde{U}x^{(k)})$$

记

$$G = -(D + \tilde{L})^{-1} \tilde{U};$$

----- Gauss-Seidel迭代矩阵

$$f_G = (D + \tilde{L})^{-1} b$$

$$\Rightarrow x^{(k+1)} = Gx^{(k)} + f_G$$

例.

用高斯-赛德尔迭代法重新求解方程组

$$\begin{cases} 20x_1 + 2x_2 + 3x_3 = 24 \\ x_1 + 8x_2 + x_3 = 12 \\ 2x_1 - 3x_2 + 15x_3 = 30 \end{cases}$$

解: 按迭代公式, 得高斯-赛德尔迭代格式

$$\begin{cases} x_1^{(k+1)} = (24 - 2x_2^{(k)} - 3x_3^{(k)}) / 20 \\ x_2^{(k+1)} = (12 - x_1^{(k+1)} - x_3^{(k)}) / 8 \\ x_3^{(k+1)} = (30 - 2x_1^{(k+1)} + 3x_2^{(k+1)}) / 15 \end{cases}$$

取  $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, x_3^{(0)})^T = (0, 0, 0)^T$  令  $k = 0, 1, 2, \dots$

$$x_1^{(1)} = (-2x_2^{(0)} - 3x_3^{(0)} + 24) / 20 = 1.2$$

$$x_2^{(1)} = (-x_1^{(1)} - x_3^{(0)} + 12) / 8 = (-1.2 + 12) / 8 = 1.35$$

$$x_3^{(1)} = (-2x_1^{(1)} + 3x_2^{(1)} + 30) / 15 = 2.11$$

$$x^{(1)} = [1.2, 1.35, 2.11]^T \quad \|x^{(1)} - x^{(0)}\|_{\infty} = 2.11$$

$$x_1^{(2)} = (-2x_2^{(1)} - 3x_3^{(1)} + 24) / 20 = 0.7485$$

$$x_2^{(2)} = (-x_1^{(2)} - x_3^{(1)} + 12) / 8 = 1.1426875$$

$$x_3^{(2)} = (-2x_1^{(2)} + 3x_2^{(2)} + 30) / 15 = 2.1287375$$

$$x^{(2)} = [0.7485, 1.1426875, 2.1287375]^T$$

$$x^{(1)} = [1.2, 1.35, 2.11]^T$$

$$x^{(2)} = [0.7485, 1.1426875, 2.1287375]^T$$

$$x^{(3)} = [0.766420625, 1.138105234, 2.125431630]^T$$

$$x^{(4)} = [0.767374732, 1.138399205, 2.125363210]^T$$

.....

$$x^{(8)} = [0.767353807, 1.138409760, 2.125368111]^T$$

$$= x^{(9)} \quad \text{故 } x \approx x^{(8)}。$$

在计算机上，用高斯-赛德尔迭代法求解方程组时，

当  $\max_i |x_i^{(k)} - x_i^{(k+1)}| < \varepsilon$  时，停止迭代，

## 计算步骤

(1) 对  $i=1\sim n$  令  $x_i \leftarrow 0$

(2)  $D \leftarrow 0$

(3) 对  $i=1\sim n$  做

$$\left\{ \begin{array}{l} \text{令 } y = b_i \\ \text{对 } j=1\sim n \text{ 但 } j \neq i \text{ 令 } y \leftarrow y - a_{ij}x_j \\ \text{令 } y \leftarrow y/a_{ii} \\ \text{若 } |x_i - y| > D \text{ 则令 } D \leftarrow |x_i - y| \\ \text{令 } x_i = y \end{array} \right.$$

(4) 对  $D \geq \varepsilon$  则转到(2)

(5) 输出  $x_i$  ( $i=1\sim n$ ) 并停止计算

## 雅可比(Jacobi)

(1) 对  $i=1\sim n$  令  $x_i \leftarrow 0$

(2)  $D \leftarrow 0$

(3) 对  $i=1\sim n$  做

$$\left\{ \begin{array}{l} \text{令 } y_i = b_i \\ \text{对 } j=1\sim n \text{ 但 } j \neq i \text{ 令 } \underline{y_i \leftarrow y_i - a_{ij}x_j} \\ \text{令 } y_i \leftarrow y_i / a_{ii} \\ \text{若 } |x_i - y_i| > D \text{ 则令 } D \leftarrow |x_i - y_i| \end{array} \right.$$

(4) 对  $i=1\sim n$  令  $x_i \leftarrow y_i$

(5) 对  $D \geq \varepsilon$  则转到(2)

(6) 输出  $x_i$  ( $i=1\sim n$ ) 并停止计算

## 高斯-赛德尔(Gauss-Seidel)

(1) 对  $i=1\sim n$  令  $x_i \leftarrow 0$

(2)  $D \leftarrow 0$

(3) 对  $i=1\sim n$  做

$$\left\{ \begin{array}{l} \text{令 } y = b_i \\ \text{对 } j=1\sim n \text{ 但 } j \neq i \text{ 令 } \underline{y \leftarrow y - a_{ij}x_j} \\ \text{令 } y \leftarrow y / a_{ii} \\ \text{若 } |x_i - y| > D \text{ 则令 } D \leftarrow |x_i - y| \\ \text{令 } x_i = y \end{array} \right.$$

(4) 对  $D \geq \varepsilon$  则转到(2)

(5) 输出  $x_i$  ( $i=1\sim n$ ) 并停止计算

### 3.6.4 逐次超松弛迭代法或SOR法

SOR法的构造方法:

从近似解 $x^{(k)}$ 出发, 先用Gauss-Seidel迭代格式计算一步, 将计算结果记为 $\tilde{x}_i^{(k+1)}$

$$\text{记 } \Delta x_i = \tilde{x}_i^{(k+1)} - x_i^{(k)}$$

$$\text{令新的近似解 } x_i^{(k+1)} = x_i^{(k)} + \omega \Delta x_i$$

松弛因子

$$\begin{aligned} x_i^{(k+1)} &= x_i^{(k)} + \omega \Delta x_i = x_i^{(k)} + \omega (\tilde{x}_i^{(k+1)} - x_i^{(k)}) \\ &= (1 - \omega) x_i^{(k)} + \omega \tilde{x}_i^{(k+1)} \end{aligned}$$

# 逐次超松弛迭代法或SOR法的迭代公式

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \omega(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)}) / a_{11} + (1 - \omega)x_1^{(k)} \\ x_2^{(k+1)} = \omega(b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)}) / a_{22} + (1 - \omega)x_2^{(k)} \\ \dots\dots\dots \\ x_i^{(k+1)} = \omega(b_i - a_{i1}x_1^{(k+1)} - \cdots - a_{i,i-1}x_{i-1}^{(k+1)} - a_{i,i+1}x_{i+1}^{(k)} - \cdots - a_{in}x_n^{(k)}) / a_{ii} + (1 - \omega)x_i^{(k)} \\ \dots\dots\dots \\ x_n^{(k+1)} = \omega(b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)}) / a_{nn} + (1 - \omega)x_n^{(k)} \end{array} \right.$$

当ω=1时就是高斯-赛德尔迭代法



在SOR法中，**松弛因子的取值对迭代公式的收敛速度影响极大。**

实际计算时，可以根据方程组的系数矩阵的性质，或结合实践计算的选取松弛因子。

**逐次超松弛迭代法的矩阵形式**

$$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega D^{-1} (b - \tilde{L}x^{(k+1)} - \tilde{U}x^{(k)})$$



$$(D + \omega \tilde{L})x^{(k+1)} = [(1 - \omega)D - \omega \tilde{U}]x^{(k)} + \omega b$$

$$(D + \omega \tilde{L})x^{(k+1)} = [(1 - \omega)D - \omega \tilde{U}]x^{(k)} + \omega b$$

$$\Rightarrow x^{(k+1)} = S_{\omega}x^{(k)} + f_{\omega}$$

其中  $S_{\omega} = (D + \omega \tilde{L})^{-1}[(1 - \omega)D - \omega \tilde{U}]$

$$f_{\omega} = \omega(D + \omega \tilde{L})^{-1}b$$

例3.12 用SOR方法解方程组

$$\begin{bmatrix} -4 & 1 & 1 & 1 \\ 1 & -4 & 1 & 1 \\ 1 & 1 & -4 & 1 \\ 1 & 1 & 1 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

(它的精确解为 $x^*=(-1,-1,-1,-1)^T$ )

解 取 $x^{(0)}=0$ , 迭代公式为

$$\begin{cases} x_1^{(k+1)} = x_1^{(k)} - \omega(1 + 4x_1^{(k)} - x_2^{(k)} - x_3^{(k)} - x_4^{(k)}) / 4 \\ x_2^{(k+1)} = x_2^{(k)} - \omega(1 - x_1^{(k+1)} + 4x_2^{(k)} - x_3^{(k)} - x_4^{(k)}) / 4 \\ x_3^{(k+1)} = x_3^{(k)} - \omega(1 - x_1^{(k+1)} - x_2^{(k+1)} + 4x_3^{(k)} - x_4^{(k)}) / 4 \\ x_4^{(k+1)} = x_4^{(k)} - \omega(1 - x_1^{(k+1)} - x_2^{(k+1)} - x_3^{(k+1)} + 4x_4^{(k)}) / 4 \end{cases}$$

$$x_i^{(k+1)} = \omega(b_i - a_{i1}x_1^{(k+1)} - \dots - a_{i,i-1}x_{i-1}^{(k+1)} - a_{i,i+1}x_{i+1}^{(k)} - \dots - a_{in}x_n^{(k)}) / a_{ii} + (1 - \omega)x_i^{(k)}$$

$$x_i^{(k+1)} = x_i^{(k)} + \omega(b_i - a_{i1}x_1^{(k+1)} - \dots - a_{i,i-1}x_{i-1}^{(k+1)} - a_{i,i+1}x_{i+1}^{(k)} - \dots - a_{in}x_n^{(k)}) / a_{ii}$$

取 $\omega=1.3$ ，第11次迭代结果为

$$x^{(11)}=(-0.999\ 996\ 46, -1.000\ 003\ 10, -0.999\ 999\ 53, -0.999\ 999\ 12)^T$$

$$\|\varepsilon^{(11)}\| \leq 0.46 \times 10^{-5}$$

对 $\omega$ 取其他值，迭代次数不同。

松弛因子 $\omega$	迭代次数	松弛因子 $\omega$	迭代次数
1.0	22	1.5	17
1.1	17	1.6	23
1.2	12	1.7	33
1.3	11	1.8	53
1.4	14	1.9	109

## 雅可比迭代格式

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)}) \\ \dots\dots\dots \\ x_i^{(k+1)} = \frac{1}{a_{ii}} (b_i - a_{i1}x_1^{(k)} - \cdots - a_{i,i-1}x_{i-1}^{(k)} - a_{i,i+1}x_{i+1}^{(k)} - \cdots - a_{in}x_n^{(k)}) \\ \dots\dots\dots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)}) \end{array} \right.$$

# 高斯-赛德尔(Gauss-Seidel)迭代法或称逐个代换法

迭代公式

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (-a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)} + b_2) \\ \dots\dots\dots \\ x_i^{(k+1)} = \frac{1}{a_{ii}} (b_i - a_{i1}x_1^{(k+1)} - \cdots - a_{i,i-1}x_{i-1}^{(k+1)} - a_{i,i+1}x_{i+1}^{(k)} - \cdots - a_{in}x_n^{(k)}) \\ \dots\dots\dots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)}) \end{array} \right.$$

Jacobi迭代格式矩阵形式

$$x^{(k+1)} = D^{-1}[b - (\tilde{L} + \tilde{U})x^{(k)}]$$

$$x^{(k+1)} = Jx^{(k)} + f_J$$

$$J = -D^{-1}(\tilde{L} + \tilde{U})$$

-----Jacobi迭代矩阵

$$f_J = D^{-1}b$$

## 高斯-赛德尔(Gauss-Seidel)迭代法的矩阵形式

$$x^{(k+1)} = D^{-1}(b - \tilde{L}x^{(k+1)} - \tilde{U}x^{(k)})$$

$$\Rightarrow x^{(k+1)} = (D + \tilde{L})^{-1}(b - \tilde{U}x^{(k)})$$

记  $G = -(D + \tilde{L})^{-1}\tilde{U};$  ----- Gauss-Seidel迭代矩阵

$$f_G = (D + \tilde{L})^{-1}b$$

$$\Rightarrow x^{(k+1)} = Gx^{(k)} + f_G$$



### 3.6.5 迭代法的收敛性

设线性方程组  $Ax = b$  -----(3.29)

等价方程组  $x = Bx + f$  -----(3.30)

相应的迭代格式是

$$x^{(k+1)} = Bx^{(k)} + f \quad (k = 0, 1, 2, \dots) \text{ -----(3.31)}$$

**问题：迭代矩阵 $B$ 满足什么条件时，由迭代格式产生的向量序列 $\{x^{(k)}\}$ 收敛到 $x^*$ ？**

### 定义3.4谱半径


定义3.4 设 $A \in \mathbb{R}^{n \times n}$ 的特征值为 $\lambda_i (i=1,2,\dots,n)$ , 则称

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i| \quad \text{为} A \text{的谱半径}$$

➤ 谱半径 /\* spectral radius \*/

定义 矩阵 $A$ 的谱半径记为

$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$ , 其中 $\lambda_i$ 为  
 $A$ 的特征根。



**定理3.11.** (迭代法基本定理) 迭代格式(3.31)  $x^{(k+1)} = Bx^{(k)} + f$

对于任意初值 $x^{(0)}$ 均收敛的充要条件是  $\rho(B) < 1$

证 充分性: 设  $\rho(B) < 1$  , 则1不是B的特征值, 因而  $|I - B| \neq 0$

$\implies (I - B)x = f$  有唯一解 $x^*$ , 即

$$x^* = Bx^* + f$$

误差向量

$$\begin{aligned}\varepsilon^{(k)} &= x^* - x^{(k)} = (Bx^* + f) - (Bx^{(k-1)} + f) = B\varepsilon^{(k-1)} \\ &= B^k \varepsilon^{(0)} \quad (k = 1, 2, \dots)\end{aligned}$$

$$\varepsilon^{(k)} = x^* - x^{(k)} = B^k \varepsilon^{(0)} \quad (k = 1, 2, \dots)$$

$$\because \rho(B) < 1 \text{ 时, } \lim_{k \rightarrow \infty} B^k = 0 \quad \therefore \lim_{k \rightarrow \infty} \varepsilon^{(k)} = 0$$

$$\text{即 } \lim_{k \rightarrow \infty} x^{(k)} = x^*$$

必要性：设  $\lim_{k \rightarrow \infty} x^{(k)} = x^*$ ，其中  $x^{(k+1)} = Bx^{(k)} + f$

$$\text{两边取极限得 } x^* = Bx^* + f$$

从而有误差向量

$$\begin{aligned} \varepsilon^{(k)} &= x^* - x^{(k)} = (Bx^* + f) - (Bx^{(k-1)} + f) = B\varepsilon^{(k-1)} \\ &= B^k \varepsilon^{(0)} \quad (k = 1, 2, \dots) \end{aligned}$$

$$\varepsilon^{(k)} = x^* - x^{(k)} = B^k \varepsilon^{(0)} \quad (k = 1, 2, \dots)$$

由于 $x^{(0)}$ 是任意的, 因而 $\varepsilon^{(0)}$ 也是任意的, 所以

$$\lim_{k \rightarrow \infty} B^{(k)} \varepsilon^{(0)} = 0 \Rightarrow \lim_{k \rightarrow \infty} B^k = 0$$

由定理3.10得  $\rho(B) < 1$ . 证毕。

推论1 若 $\|B\| < 1$ , 则迭代格式(3.31)  $x^{(k+1)} = Bx^{(k)} + f$  ( $k = 0, 1, 2, \dots$ ) 收敛

证:  $\because \rho(B) \leq \|B\| < 1$  (定理3.8)  $\left. \vphantom{\begin{array}{l} \text{证: } \because \rho(B) \leq \|B\| < 1 \text{ (定理3.8)} \\ \text{定理3.11} \end{array}} \right\} \Rightarrow \text{迭代格式收敛}$

定理3.10 设  $B \in R^{n \times n}$ , 则  $\lim_{k \rightarrow \infty} B^k = 0$  的充分必要条件是  $\rho(B) < 1$

定理3.8 设  $A \in R^{n \times n}$ , 则  $\rho(A) \leq \|A\|$  其中  $\|A\|$  为  $R^{n \times n}$  上的任一范数。

推论2 设  $Ax = b$ , 其中  $A = D + \tilde{L} + \tilde{U}$  为非奇异矩阵且  $D$  也非奇异, 则

(1) Jacobi迭代法收敛的充分必要条件是

$$\rho(J) < 1, \text{ 其中 } J = -D^{-1}(\tilde{L} + \tilde{U})$$

(2) Gauss-Seidel迭代法收敛的充分必要条件是

$$\rho(G) < 1, \text{ 其中 } J = -(D + \tilde{L})^{-1}\tilde{U}$$

(3) SOR迭代法收敛的充分必要条件是

$$\rho(S_{\omega}) < 1, \text{ 其中 } S_{\omega} = (D + \omega\tilde{L})^{-1}[(1 - \omega)D - \omega\tilde{U}]$$

**例3.13** 判别下列方程组用Jacobi法和Gauss-Seidel法求解是否收敛

$$\begin{pmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

**解:** (1) 求Jacobi法的迭代矩阵

$$\begin{aligned} J = -D^{-1}(\tilde{L} + \tilde{U}) &= -\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 0 & 2 & -2 \\ 1 & 0 & 1 \\ 2 & 2 & 0 \end{pmatrix} \\ &= \begin{pmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{pmatrix} \end{aligned}$$

$$\det(\lambda I - J) = \det \begin{pmatrix} \lambda & 2 & -2 \\ 1 & \lambda & 1 \\ 2 & 2 & \lambda \end{pmatrix} = \lambda^3 = 0$$

$$\text{所以 } \lambda_{1,2,2} = 0 \quad \rho(J) = \max(|\lambda|) = 0 < 1$$

即Jaobi迭代法收敛

(2) 求高斯-赛德尔法的迭代矩阵

$$G = -(D + \tilde{L})^{-1} \tilde{U} = - \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & 2 & 1 \end{pmatrix}^{-1} \cdot \begin{pmatrix} 0 & 2 & -2 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix}$$



$$G = \begin{pmatrix} 0 & -2 & 2 \\ 0 & 2 & -3 \\ 0 & 0 & 2 \end{pmatrix}$$

$$\lambda_1 = 0 \quad \lambda_{2,3} = 2$$

$$\rho(G) = \max(|\lambda|) = 2 > 1$$

所以高斯-赛德尔迭代法发散

或 特征方程为

$$\det(\lambda I - G) = \det[\lambda I + (D + \tilde{L})^{-1} \tilde{U}]$$

$$= \det(D + \tilde{L})^{-1} \det[\lambda(D + \tilde{L}) + \tilde{U}] = 0$$

$$\because \det(D + \tilde{L})^{-1} \neq 0 \quad \therefore \det[\lambda(D + \tilde{L}) + \tilde{U}] = 0$$

即

$$\begin{aligned} \det[\lambda(\tilde{L} + D) + \tilde{U}] &= \begin{vmatrix} \lambda & 2 & -2 \\ \lambda & \lambda & 1 \\ 2\lambda & 2\lambda & \lambda \end{vmatrix} = \lambda(\lambda^2 - 2\lambda) - 2(\lambda^2 - 2\lambda) \\ &= \lambda(\lambda - 2)^2 \end{aligned}$$

$$\lambda_1 = 0 \quad \lambda_{2,3} = 2$$

$$\rho(G) = \max(|\lambda|) = 2 > 1$$

所以高斯-赛德尔迭代法发散

**定理3.12** 设  $Ax = b$ ，如果  $A$  为严格对角占优阵，则Jacobi迭代法和Gauss-Seidel 迭代法均收敛。

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, \quad (i = 1, 2, \dots, n)$$

$A$  的每一行对角元素的绝对值都严格大于同行其他元素绝对值之和。称  $A$  为严格对角占优

**定理3.13** 设解  $Ax = b$  的SOR法收敛，则  $0 < \omega < 2$

**定理3.14** 设  $Ax = b$ ，如果  $A$  为对称正定矩阵，且  $0 < \omega < 2$ ，则SOR 迭代法收敛。